

# Gauss-Markov feltevések

Ahhoz, hogy az OLS elven becsült lineáris regressziónak fennálljanak bizonyos előnyös tulajdonságai, meghatározott feltevéseknek teljesülniük kell:

- 1 **Modell linearitás:** Feltesszük, hogy az  $Y$  és az  $X$  közötti kapcsolat lineárisan leírható
- 2 Az adatok a sokaság **véletlen mintái**. A legtöbbször használt i.i.d. ennél szigorúbb, tehát teljesíti a véletlen mintás feltevést.
- 3  $X$  mátrix **teljes oszlop rangú**. Ezen feltevés alapján tehát nincs egzakt multikolinearitás. Ha ezt nem teszük fel, akkor  $(X^T X)$  nem lenne invertálható tetszőleges  $X$  esetén.
- 4  $\mathbb{E}[\epsilon|X] = 0$ . Ez a feltevés (0 feltételes átlag) alapján a hibatagok átlaga 0. Ebből következik, hogy  $\mathbb{E}(Y) = X\beta$ .
- 5  $\mathbb{E}[\epsilon\epsilon^T|X] = \sigma^2 I$ . Ezen feltevés szerint a hibatagok homoszkedasztikusak és autokorrelálatlanok.

# OLS torzítatlanság

A Gauss-Markov feltevések (1.-4.) alapján  $\hat{\beta}_{OLS}$  torzítatlan becslője  $\beta$ -nak.  $\mathbb{E}[\hat{\beta}_{OLS}] - \beta = 0$

## Bizonyítás

$$\begin{aligned}\mathbb{E}[\hat{\beta}_{OLS}] &= \mathbb{E}[(X^T X)^{-1} X^T Y] = \mathbb{E}[(X^T X)^{-1} X^T (X\beta + \epsilon)] \\ &= \mathbb{E}[(X^T X)^{-1} X^T X \beta] + \mathbb{E}[(X^T X)^{-1} X^T \epsilon]\end{aligned}$$

- Ismerjük fel, hogy  $(X^T X)^{-1} X^T X = I$ , és  $\mathbb{E}[\beta] = \beta$  így

$$= \beta + \mathbb{E}[(X^T X)^{-1} X^T \epsilon]$$

- A 4. Gauss-Markov feltevés ( $\mathbb{E}[\epsilon|X] = 0$ ) alapján  
 $= \beta$

$$\implies \mathbb{E}[\hat{\beta}_{OLS}] - \beta = 0$$

# OLS kovariancia mátrix

A Gauss-Markov feltevések (1.-5.) alapján  $\mathbb{V}[\hat{\beta}_{OLS}] = \sigma^2(X^T X)^{-1}$

## Bizonyítás

$$\mathbb{V}[\hat{\beta}_{OLS}] = \mathbb{E}[(\hat{\beta}_{OLS} - \mathbb{E}[\hat{\beta}_{OLS}])(\hat{\beta}_{OLS} - \mathbb{E}[\hat{\beta}_{OLS}])^T]$$

$$= \mathbb{E}[(\hat{\beta}_{OLS} - \beta)(\hat{\beta}_{OLS} - \beta)^T]$$

$$= \mathbb{E}[(X^T X)^{-1} X^T \epsilon * [(X^T X)^{-1} X^T \epsilon]^T]$$

$$= \mathbb{E}[(X^T X)^{-1} X^T \epsilon \epsilon^T X (X^T X)^{-1}]$$

$$= (X^T X)^{-1} X^T \mathbb{E}[\epsilon \epsilon^T] X (X^T X)^{-1}$$

- Az 5. Gauss-Markov feltevés ( $\mathbb{E}[\epsilon \epsilon^T | X] = \sigma^2 I$ ) alapján

$$= (X^T X)^{-1} X^T \sigma^2 I X (X^T X)^{-1}$$

$$= \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

# Gauss-Markov tétel

## Gauss-Markov tétel

Ha teljesül mindegyik feltétel (1.-5.), akkor a **lineáris, torzítatlan becslők körében** az OLS-becslő **minimális varianciájú** (azaz hatásos).

Más szavakkal elmondva, az OLS-becslő **B**est, **L**inear, **U**nbiased, **E**fficient becslő, tehát **BLUE** estimator.

# Általánosított regressziós modell

Az 5.Gauss-Markov feltevés ( $\mathbb{E}[\epsilon\epsilon^T|X] = \sigma^2 I$ ) szerint a hibatagok homoszkedasztikusak és autokorrelálatlanok. Ez a feltevés gyakran túlzottan szigorú, és nem fedi le azokat az eseteket amelyekkel adatelmezés során találkozunk.

Ha a  $\mathbb{E}[\epsilon\epsilon^T|X]$  mátrix főátlójának elemei nem azonosak, akkor a hibatagok nem homoszkedasztikusak, amennyiben a főátlón kívüli elemek különböznek nullától, akkor a hibatagok között korreláció áll fent.

Bármely tetszőleges pozitív skalár  $\sigma^2$  mellett definiálható  $V(X) \equiv \mathbb{E}[\epsilon\epsilon^T|X]/\sigma^2$  és feltesszük, hogy  $V(X)$  nem szinguláris, és előre ismert. Ekkor:

$$\mathbb{E}[\epsilon\epsilon^T|X] = \sigma^2 V(X), \text{ ahol } V(X) \text{ } n \times n \text{ nem szinguláris mátrix.}$$

Amennyiben az 5.Gauss-Markov feltevést felváltjuk az előző egyenlent eredményére ( $\mathbb{E}[\epsilon\epsilon^T|X] = \sigma^2 V(X)$ ) – amely annyit feltételez, hogy a feltételes második momentum nem szinguláris – akkor az úgynevezett **általánosított regressziós modellt** kapjuk.

# Következmények

Azok a következtetések, amelyek az 5. feltevés meglétét alkalmazták nem lesznek validak az általánosított regressziós modell esetén. Tételesen:

- 1 Az OLS elvű becslés esetén a Gauss-Markov tétel nem érvényes, a

$$\hat{\beta} \equiv (X^T X)^{-1} X^T Y$$

nem a legkisebb varianciájú a lineáris, torzítatlan becslők körében (nem BLUE)

- 2 A t-érték nem követ t-eloszlást, tehát a t-teszt nem valid
- 3 A kis mintás Wald statisztika nem követ F-eloszlást, tehát a F-teszt nem valid
- 4 Az OLS becslő továbbra is torzítatlan, mert a levezetéshez erre a feltevésre nem volt szükség (lásd [itt](#))

## G-M feltevések az átlatlanosított regresszió esetén

Mivel  $V(X)$  – továbbiakban  $V$  – szimmetrikus és pozitív szemidefinit, ezért létezik olyan  $n \times n$   $C$  mátrix, amelyre igaz, hogy:

$$V^{-1} = C^T C.$$

Ez dekompozíció nem egyedi (*not unique*), tehát több  $C$  mátrixra is igaz. Ez alapján felírható egy új regressziós model a következő transzformációval:

$$\tilde{Y} \equiv CY, \tilde{X} \equiv CX, \tilde{\epsilon} \equiv C\epsilon.$$

- 1 **Modell linearitás:**  $\tilde{y} = \tilde{X}\beta + \tilde{\epsilon}$
- 2 Az adatok a sokaság **véletlen mintái**.
- 3  $\text{rank}(\tilde{X}) = \text{rank}(X)$ , mivel  $C$  nem szinguláris.  $\tilde{X}$  **teljes oszlop rangú**.
- 4  $\mathbb{E}[\tilde{\epsilon}|\tilde{X}] = C \mathbb{E}[\epsilon|X] = 0$ . A hibatagok átlaga transzformációt követően is 0.
- 5  $\mathbb{E}[\tilde{\epsilon}\tilde{\epsilon}^T|\tilde{X}] = \sigma^2 CVC^T = \sigma^2 I$ .

## GLS becslés

Mivel a transzformált modellre teljesülnek a Gauss-Markov feltevések, ezért a Gauss-Markov tételből következik, hogy az általánosított regressziós modellre alkalmazott OLS elvű becslő minimális varianciájú lesz a lineáris, torzítatlan becslők körében. Ezt a becslőt nevezzük **általánosított legkisebb négyzetek módszerének, vagy GLS elvű becslőnek**.

### GLS paraméter becslés

$$\begin{aligned}\hat{\beta}_{GLS} &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{y} \\ &= [(CX)^T (CX)]^{-1} (CX)^T Cy \\ &= (X^T C^T C X)^{-1} (X^T C^T C y) \\ &= (X^T V^{-1} X)^{-1} (X^T V^{-1} y)\end{aligned}$$

### GLS feltételes variancia

$$\mathbb{V}(\hat{\beta}_{GLS}|X) = \sigma^2 (X^T V^{-1} X)^{-1}$$



# GLS tulajdonságok

Kismintás tulajdonságok:

- 1 A GLS elvű becslő torzítatlan ( $\mathbb{E}(\hat{\beta}_{GLS}|X) = \beta$ )
- 2 A feltételes variancia arányos  $V$ -vel:  $\mathbb{V}(\hat{\beta}_{GLS}|X) = \sigma^2(X^T V^{-1} X)^{-1}$
- 3 A GLS elvű becslő hatékony, tehát minden lineáris, torzítatlan becslőnek legalább akkora a feltételes varianciája, mint a GLS feltételes varianciája.

Limitációk:

- 1 Amennyiben a 4. Gauss-Markov feltevés sérül ( $\mathbb{E}(\tilde{\epsilon}|\tilde{X}) \neq 0$ ), úgy a GLS nem lesz torzítatlan. Ez a tulajdonság az OLS esetén is fennáll, de utóbbi nagymintás tulajdonságai ezt a hátrányt orvosolják. A GLS esetében nincsenek ilyen pozitív nagymintás tulajdonságok.
- 2 A gyakorlatban nem ismerjük  $V$  mátrixot, és ezt becsülnünk kell. Ebben az esetben **Megvalósítható GLS/Feasible GLS** becslőről beszélünk.

A Feasible GLS elvű becslés lépései:

1. Becsüld meg  $\hat{\beta}$  koeficienseket OLS elvű becselővel.
2. A kapott koeficiens vektor segítségével számítsd ki a modell hibáit ( $\epsilon$ ).
3. A négyzetes hibákra becsülj egy kiegészítő regressziót ( $\hat{\omega}$ ).
4. A becsült koeficiensek ( $\hat{\omega}$ ) alapján elítsd elő  $\hat{V}$  variancia mátrixot.
5.  $\hat{V}$ -t felhasználva transzformáld  $X$  és  $Y$  változókat ( $\tilde{X}$ ,  $\tilde{Y}$ ).
6. A transzformált változókon becsüld meg  $\hat{\beta}_{GLS}$  koeficienseket OLS elvű becselővel.